

赛道三：前沿探索 AI for Research

本手册面向已报名或计划报名 GOAI 【前沿探索 | AI for Research】赛道的参赛团队，帮助选手了解赛道方向、参赛路径、各阶段提交要求、技术要求、评审标准和答疑渠道。

01 赛道概览

1.1 赛道基本信息

赛道名称	赛道三：前沿探索 AI for Research
赛道一句话介绍	本赛道聚焦 AI 与科学的交叉，鼓励参赛者围绕真实的科学问题，构建可运行的算法方案或自主探索环境，推动 AI 成为科学发现的有效工具。
题目类型	算法赛题（给定问题与评测框架，提交解法）、开放探索赛题（自定义科学问题与探索环境）
牵头单位	Datawhale

1.2 赛道背景与初心

过去两年，AI 开始深度参与科学发现本身。从 Lila Sciences 的「AI Science Factory」，到 FutureHouse Kosmos 在一天内完成六个月的研究分析量，到 AlphaEvolve 在数学和芯片设计上的自主发现，再到 2026 年 6 月 30 日 Anthropic 正式发布的 Claude Science 工作台——「工具层」的问题正在被系统性解决。

这意味着真正稀缺的，不再是会用 AI 跑实验的人，而是能把科学直觉转化为可计算探索环境的人——能重新定义「AI 时代的科学应该长什么样」的人，这正是 Track 3 要找的。

1.3 适合参赛团队

本赛题适合以下团队参与：

- 具备 AI/ML 技术能力，同时对某个科学领域（生物学、化学、材料、天文、物理等）有真实认知的跨学科团队
- 博士生、博士后、年轻 PI 及其团队，拥有真实未解科学问题并希望探索 AI 解法的研究者
- 有计算生物学、计算化学、计算材料等方向背景的高校实验室、科研团队
- 对 Agent RL、自进化系统、科学发现 benchmark 设计有研究兴趣的 AI 技术团队
- 希望通过赛事建立 AI4Science 领域影响力和社区连接的开源团队

02 奖项与资源支持

2.1 奖项设置

本赛道设置赛道奖项及相关专项激励，奖金数额均为税前金额。

奖项	数量	说明
GOAI 全场大奖	1 名	100 万 RMB
赛道冠军	2 名	各 25 万 RMB
赛道亚军	2 名	各 15 万 RMB
赛道季军	2 名	各 5 万 RMB
科学家直通奖	1-2 名	各 2 万 RMB 由科学家评委直接提名，跨两个通道，独立于冠亚季军之外。另附联合研究机会或算力资源对接。

奖项	数量	说明
范式创造奖	0-1 名	2 万 RMB 如有参赛者设计出有说服力的动态科学评测框架，由全体评委联合提名，单独颁发。
优胜奖	入围复赛团队	500RMB 纪念礼品包/队伍
参与奖	提交有效参赛方案团队	大赛纪念 T 恤/队伍

2.2 资源支持

本赛道将为复赛入围团队提供平台工具、数据集、技术文档、导师辅导和线上答疑等支持资源。

资源类型	是否提供	支持对象	说明
科学数据集	是	全体参赛者	算法类赛题的公开数据集与 Benchmark 于 7 月 15 日通过官网发布，以官网最新版本为准。
技术文档 / 教程	是	全体参赛者	含赛题说明、评测框架、环境骨架参考、样例库与提交流程。具体安排组委会将通过社群、邮件等方式另行公布。
科学家评委答疑	是	复赛团队	各方向安排在线答疑；开放探索赛题参赛者可申请问题预审（可选）。具体安排组委会将通过社群、邮件等方式另行公布。
导师辅导	是	复赛团队	复赛辅导期，覆盖方案评审、科学背景对齐与开源规范。具体安排组委会将通过社群、邮件等方式另行公布。

03 赛事阶段总览

阶段	时间	关键节点/结果	关键提交物
报名开启	7.16	报名参赛启动	报名信息
初赛	7.16-8.16	8.16 初赛作品提交截止	● 探索赛：问题定义文档（4 页） ● 算法赛：初步方案与阶段性实验结果
初赛评审	8.17-8.24	8.24 公布复赛入围队伍名单，Top 40 队伍进入复赛	无新增提交，除非组委会另行要求
复赛	8.25-9.3	9.3 复赛作品提交截止	● 探索赛：完整三件套 ● 算法赛：最终代码 + 完整实验结果
复赛评审	9.4-9.10	9.10 公布决赛入围名单，Top 20 队伍进入决赛，受邀参加线下决赛答辩，角逐最终奖项	无新增提交，除非组委会另行要求
决赛	9.22	线下决赛答辩与展示	● 探索赛：决赛路演 PPT、现场 Demo、项目一页纸、答辩材料 ● 算法赛：海报 + 展示材料
GOAI DAY / 颁奖	9.23	颁奖、项目展示和生态对接	决赛路演 PPT、现场 Demo

*赛程安排可能会根据实际推进情况灵活调整，以组委会最终通知为准。

04 赛题信息

本赛道包含两类题目。算法赛题下设多个学科方向，参赛者任选其一；开放探索赛题为开放命题，参赛者自定义问题。两类题目独立评审、独立排名。

题目类型一：算法赛题

赛题背景

AI for Science 正在成为科学研究的重要方法。算法赛题面向具备明确评测方式的科学问题，为参赛者提供清晰的任务边界、数据集与评分标准，参赛者在给定框架内提交解法，比拼算法设计与科学理解。

赛题目标

参赛团队基于组委会提供的数据集与评测框架，针对所选学科方向的科学问题完成建模与求解，形成可运行、可复现的算法方案，并说明其科学意义。

赛题方向

算法赛题下设以下方向，参赛者报名时选定一个方向。各方向的具体数据集与评测细则，以官网发布的赛题文档为准。

方向一：虚拟细胞

科学背景	围绕细胞状态、扰动响应与调控关系，构建可计算的预测与推理任务，让 AI 从拟合数据走向建模与推理细胞行为。
首期赛题	虚拟酵母扰动响应预测。基于酿酒酵母扰动蛋白质组数据，预测未见化合物、未见菌株及二者组合条件下的完整蛋白质组响应，考察模型对未知条件的外推与泛化能力。
科学意义	为菌株定向改造与优化提供数据支撑，是「AI 预测 → 湿实验验证」闭环的关键一环。

方向二：小分子-蛋白质结合轨迹预测

科学背景	小分子与蛋白质的结合过程本质上是一个动态演化过程，而非静态结构预测。准确建模和拟合结合轨迹（binding dynamics）对于理解分子识别机制、揭示结合动力学以及推动药物设计具有重要意义。
赛题要求	给定一组小分子-蛋白质复合物的分子动力学轨迹作为训练数据，要求模型学习其动力学规律，并预测未见过的全新复合物上的结合动力学轨迹，从而评估模型的泛化能力。
评测标准	在 MISATO（Nature Computational Science, 2024）数据集上统一评测，并与 NeuralMD（Nature Communications, 2025）等 baseline 比较。
数据集	MISATO 是目前规模最大的公开小分子-蛋白质结合动力学数据集之一，包含 13,066 个复合物轨迹用于训练，1,357 个复合物轨迹用于验证和测试。

方向三：材料科学文献驱动的科学发现智能体

科学背景	材料科学的知识高度沉淀于文献之中——组分、结构、工艺与性能之间的关联，大量以非结构化形式散落在数十年论文与专著里，人工阅读的覆盖能力与大模型时代的文献规模已形成根本性落差。以大模型为核心的智能体，使「自主阅读文献—形成科学判断—调用工具验证—沉淀科学结论」的闭环首次具备工程可行性，材料领域的知识生产正逐步走向自动化。
赛题要求	基于大规模材料科学文献库，构建能够自主阅读、推理并产出可验证科学发现的智能体系统。要求根据文献调研结果，产出具有可证伪性的科学发现—包括材料_性质关联、隐藏知识连接、新材料设计假设等。所有队伍须先完成「文献调研 Agent」基础任务（自主检索筛选、知识抽取、Research Gap 识别、结构化调研报告），再从构效关系发现、模拟方法

	创新、合成路线与工艺设计三条路线中任选其一深入。
评测标准	基础任务(文献调研那部分)应该考察:Research Gap 的识别准确率与新颖性口文献溯源的完整性与可信度调研报告的结构化程度与可读性等进阶任务的考察标准依赖于具体路线，详见下文。
数据与资源	推荐使用 Sciverse 科学智能数据库（2500 万+篇经深度解析的开放获取文献，支持语义检索与全文定位）与开源文档解析引擎 MinerU；鼓励通过 Sciverse API 的 MCP/Skill 接入，其调用记录天然构成可审计的证据链。开放数据集可经 Hugging Face（opendatalab/Sci-Base）获取，具体以官网赛题文档为准。
科学意义	推动 AI for 材料领域的进步，逐步走向材料领域的知识生产自动化，为「AI 发现→计算/实验验证」的科研闭环提供可复用的智能体范式。

题目类型二：开放探索赛题

赛题背景

部分重要的科学问题尚未被结构化为标准的评测任务。开放探索赛题面向这类问题，鼓励参赛者自己提出并定义一个值得探索的科学问题，把它转化为一个 Agent 可以进入、尝试、修正并持续探索的环境。

赛题目标

参赛团队在自己所在的科学或研究领域中，找到一个尚无公认答案的问题，定义相应的探索环境与发现信号，构建可运行的探索系统，并说明探索过程带来的科学或研究价值。

参赛要求（三条核心约束）

- 真实问题：所聚焦的问题必须真实存在，目前没有公认答案或尚未被充分结构化，需用文献、数据、专家经验或现实系统说明这一点。

- 探索环境：需说明 Agent 在什么环境里行动、看到什么、能改变什么、如何获得反馈。环境可以是实验模拟器、文献空间、市场微观结构模拟、分子生成反馈循环、城市干预仿真等。
- 发现信号：需提前说明什么算发现信号——可以是正向发现、异常、反例、稳定负结果、失败模式，也可以是对原问题定义的修正。

适用领域：不限学科。自然科学、工程科学，以及城市系统、金融市场、社会科学、公共政策等复杂系统方向均可参与，但项目须指向真实研究问题，而非单纯的业务优化或应用集成。

参赛支持材料

为帮助参赛者理解开放命题，组委会将提供样例库（正面 / 负面样例）、轻量环境骨架参考与创新矩阵说明。环境骨架帮助参赛者说明哪些部分固定、哪些部分可探索、如何记录运行日志。相关材料将作为辅助资料逐步发布。

05 参赛作品提交要求

两类题目均按初赛、复赛、决赛三阶段提交，提交材料随题目类型不同而有所区别。

5.1 算法赛题提交要求

阶段	是否必交	提交材料	内容说明
初赛	是	方案说明文档、技术路线概述	说明所选方向、科学问题理解、技术方案与预期方法路线；可附初步实验或可行性验证。
复赛	是	可运行代码仓库、实验结果报告、科学意义阐释、依赖披露	提交完整代码（含 README、环境配置、运行说明）、完整实验结果，以及方法的科学意义说明与依赖/授权披露。
决赛	是	海报 / 路演材料、现场展	聚焦方法、核心结果与科学意义；现场展示与

		示、最终代码仓库、项目一页纸	专家问答。
--	--	----------------	-------

5.2 开放探索赛题提交要求

阶段	是否必交	提交材料	内容说明
初赛	是	问题定义文档（≤ 4 页）	说明看见了什么问题、为什么 AI 可以介入、如何定义探索环境、什么算发现信号、最小参照系是什么。
复赛	是	最小可运行探索环境、探索日志、参照系设计	提交可运行环境、至少一次完整运行日志、随机探索或平凡解等参照系，以及 README 与复现说明。
决赛	是	探索报告、答辩材料、最终代码仓库	说明探索过程中的正结果、负结果、异常或问题修正究竟意味着什么；负结果被明确允许。

06 开源与合规要求

是否要求开源代码	初赛不强制提交代码，但需说明开源计划与边界；进入复赛 / 决赛后需提交可运行代码或等价可验证材料，并提供可访问仓库。
是否要求部署 / 复现说明	是。复赛起需提供运行入口、依赖安装、配置方法、随机种子与复现说明。
是否允许使用商业 API	允许，但必须披露调用环节、费用假设、权限范围、可替代性与对可复现性的影响。

是否允许使用闭源模型	允许，但必须说明使用范围、原因、替代方案、迁移成本与对可复现性的影响。
是否允许基于已有项目继续开发	允许，但需说明原项目来源、团队贡献范围、新增创新点与原协议兼容性。
数据来源与授权	使用公开数据集需遵守对应授权协议；开放探索赛题使用的数据需说明来源与授权状态。算法赛题的官方数据集使用规范以赛题文档为准。
第三方依赖披露	需完整披露开源依赖、商业服务、外部数据来源、许可证与关键版本信息。

07 评审标准

两类题目采用不同的评审维度，独立评审、独立排名。

7.1 算法赛题评审维度

评审维度	建议权重	说明
技术性能	45%	所选方向对应的量化指标（如结构预测精度、预测误差、路径准确率等）。
科学意义	30%	结果对该科学领域是否有真实意义，是否超出已有工作的边界。
方法创新性	20%	方法是否有新颖的技术设计，而非对已有方法的简单集成。

开源贡献	5%	代码、模型或数据处理管线的开源质量与可复用性，及可被社区接续使用与复现的程度。
------	----	---

7.2 开放探索赛题评审维度

评审维度	建议权重	说明
问题定义与环境设计质量	45%	问题是否真实且切片得当；环境是否抓住问题本质；固定部分、可探索部分和反馈机制是否清楚。
探索过程与科学 / 研究信号	35%	是否有意义信号：正向发现、异常、反例、被清晰解释的负结果，或问题定义的有效修正。
可检查性与可延续性	20%	是否有最小参照系、运行日志、复现说明和后续研究路径；能否沉淀为社区可接续的问题包或环境包。

08 资源支持说明

资源类型	是否提供	支持对象	说明
科学数据集	是	全体参赛者	算法类赛题的公开数据集与 Benchmark 于 7 月 15 日通过官网发布，以官网最新版本为准。
算力资源	待确认	入围团队	用于算法方案运行验证、模型训练与探索环境运行。

LLM API / 模型额度	部分提供	参赛团队	部分赛题（如自动出题-解题类）报销指定 LLM API 调用与 coding agent 费用；其余待确认。
自动化评审平台	规划中	算法类赛题	算法赛的代码提交、自动运行与结构化评分，拟对接成熟赛事平台，具体以官网通知为准。
技术文档 / 教程	是	全体参赛者	含赛题说明、评测框架、环境骨架参考、样例库与提交流程。
科学家评委答疑	是	全体参赛者	各方向安排在线答疑；开放探索赛题参赛者可申请问题预审（可选）。
导师辅导	待确认	入围团队	复赛辅导期，覆盖方案评审、科学背景对齐与开源规范。

资源使用说明：涉及商业 API、闭源模型、私有数据或受限资源的使用，需在提交材料中说明用途、成本、权限范围、替代方案与合规限制。具体申请方式以官网公告和官方表单为准。

09 赛题 FAQ

Q1：算法赛题和开放探索赛题，我该选哪个？

两类题目面向不同的参赛方式。如果你希望在一个明确的科学问题与评测框架下比拼算法，选算法赛题；如果你有自己想探索的科学问题、希望自定义问题与探索环境，选开放探索赛题。两者独立评审、独立排名。

Q2：开放探索赛题没有标准答案，怎么评审？

开放探索赛题评审的是问题定义与环境设计质量、探索过程与研究信号、以及可检查性与可延续性。负结果被明确允许——关键是能否清晰解释探索过程说明了什么。

Q3：算法赛题必须从零做，还是可以基于现有方法改进？

可以基于现有方法继续开发，但需说明原方法来源、团队的新贡献点，以及相对已有 baseline 的改进。

Q4：是否必须开源代码？

初赛不强制提交代码，但需说明开源计划与边界；进入复赛和决赛后需提交可运行代码或等价可验证材料，并提供可访问仓库。

Q5：数据集在哪里获取？

算法类赛题的公开数据集与 Benchmark 于 7 月中下旬通过官网发布。请以官网发布的最新版本为准，本资料仅作方向说明。

Q6：可以使用商业 API 或闭源模型吗？

可以，但必须披露调用环节、费用假设、权限范围、可替代方案，以及对方案可复现性的影响。

Q7：如何申请算力 / API / 平台资源？

按赛道公告和官方表单统一申请。报名后开放数据集访问说明；入围复赛后分阶段发放算力、模型或 API 资源，具体流程以官网通知为准。

本资料为当前规划版本，赛程、奖项、资源、评委与提交方式可能根据赛事安排调整，最终以 GOAI 世界人工智能开源大赛组委会正式发布为准。

算法赛题

题目类型一 · 详细说明

详细说明文档 · 2026 年 7 月 · 规划版本

01 赛题类型定位与评分总则

AI for Science 正在成为科学研究的重要方法。算法赛题面向具备明确评测方式的科学问题，为参赛者提供清晰的任务边界、数据集与评分标准；参赛者在给定框架内提交解法，比拼算法设计与科学理解。

参赛团队报名时在下列学科方向中任选其一，基于组委会提供的数据集与评测框架完成建模与求解，形成可运行、可复现的算法方案，并说明其科学意义。

统一评分、单一冠军：算法赛题不按方向分设排名，而是以统一的评审标准对所有方向的作品同台评分、统一排名，全赛道最终决出一名算法赛题冠军。方向只是参赛的切入口，而非独立的排名单元——各方向依其学科特点采用相应的方向内量化指标（见第二节），这些指标先在方向内归一化为可比成绩，再经统一评审框架（见第四节）折算，进入跨方向的总排名。

02 赛题方向详解

方向一：虚拟细胞（虚拟酵母扰动响应预测）

科学背景：

围绕细胞状态、扰动响应与调控关系，构建可计算的预测与推理任务，让 AI 从拟合数据走向建模与推理细胞行为。核心科学问题是：在有限的扰动蛋白质组数据下，如何构建能泛化到未知化学扰动与未知遗传背景的虚拟酵母模型，准确预测完整蛋白质组响应，并识别关键差异表达蛋白、药物响应模式与潜在调控机制。

赛题任务：

主榜任务为酿酒酵母的扰动蛋白质组预测。参赛队使用组委会提供的 train_val 数据，学习跨菌株、化学扰动、培养基、温度、时间点与测量上下文的蛋白质组响应规律，并预测独立测试集样本的完整 log2 蛋白质组向量。赛题考察模型能否同时刻画生物条件与测量上下文，以及能否稳健外推到未见化合物、未见菌株及其组合。

数据范围：

组委会提供两个输入文件：train_val 与 test。train_val 含样本 metadata、条件信息、测量上下文与蛋白质组标签，用于训练与内部验证；参赛队可自行在 train_val 内划分训练/验证，或采用交叉验证做模型选择。test 为独立评测集，发布样本 ID、生物条件与测量上下文，蛋白质组真值标签保留、由组委会离线评分。

每个样本对应一个固定蛋白顺序的 log2 蛋白丰度向量。输入特征包括生物条件（菌株、化合物、培养基、温度、时间）与测量上下文（数据来源、仪器、板号等采集元数据）；测量上下文用于吸收测量过程引入的变异，而泛化类型仍由菌株与化合物实体的可见性定义。

数据类型	建议公开字段	用途
扰动蛋白质组数据	菌株、化合物/处理、培养基、温度、时间点、重复、蛋白丰度、批次	主预测目标；评估模型对细胞响应状态的刻画能力
公共外部数据	公开基因组、转录组、蛋白质组、代谢通路、基因注释与文献数据库	开放知识榜可用；封闭数据榜仅用于赛后解释或非排名分析

数据保密与使用限制：

该数据集属于非公开资料。参与团队仅可在开发、调试、测试、提交及评估其参赛作品时所需范围内使用该数据集，且不得将其相关数据用于与本次竞赛无关的任何用途。

若出现任何违反本条款的行为，组委会保留采取适当措施的权力，包括但不限于限制数据访问、要求进行整改、取消参赛队伍的参赛资格、撤销评价结果、追回奖项或收益，以及取消获奖资格。若由此造成任何损失或涉嫌违反适用法律或法规的情况，组委会及赛道主办方保留根据适用法律追究法律责任的权利。详情请参阅《参与者协议》。

赛道设置：封闭数据榜 与 开放知识榜

本方向内设两个榜、分别排名：

- **封闭数据榜**：仅使用组委会发布的训练数据、字段字典与官方基线，评价模型在公平比较下从内部数据学习规律的能力。
- **开放知识榜**：在封闭数据基础上，可使用公开数据库、文献知识、通路模型与工具调用（须完整记录外部资源），鼓励结合先验知识、科学推理或智能体工具链，但要求结果可复现。

评测集：三类泛化场景

验证集用于模型选择与阶段反馈，最终测试集用于排名。模型需要面对三类泛化场景：

评价场景	划分方式	考察能力
S1	已见菌株 + 未见化合物	对新扰动的外推能力
S2	未见菌株 + 已见化合物	对新遗传背景的外推能力
S3	未见菌株 + 未见化合物	对双重未知组合的泛化能力

评分方法：

最终成绩由若干评分模块按权重组合，各模块作用于相应的数据划分（split）。所有参照、归一化统计与对照匹配规则须仅用训练数据冻结。

评分模块	权重	计算方式、适用划分与取向
绝对保真度（全蛋白质组真实性）	20%	适用全部划分。逐样本 corr / R^2 （每个样本的预测向量对真值向量）与逐蛋白 corr / R^2 （每个蛋白跨样本）：PCC 刻画蛋白谱形状， R^2 刻画幅度与校准（可为负）。样本轴与蛋白轴分别聚合，避免高丰度易预测蛋白掩盖困难样本。

评分模块	权重	计算方式、适用划分与取向
匹配对照原始 FC（扰动效应预测）	25%	所有 OOD 划分的核心指标。 $\Delta_{\text{pred}} = \hat{y}_{\text{treat}} - y_{\text{control}}$, $\Delta_{\text{true}} = y_{\text{treat}} - y_{\text{control}}$, 计算 $\text{PCC}(\Delta_{\text{pred}}, \Delta_{\text{true}})$ 。对照须匹配来源、菌株、培养基、温度、时间、仪器、板号, 并按官方规则匹配到 DMSO 或 Water。评估模型能否捕捉药物/扰动引起的真实蛋白质组变化。
上下文均值残差（新化合物的特异响应）	20%	适用 test_chem_only（对应 S1）等新化合物划分。 μ_{ctx} = 同上下文下训练药物的 Δ_{true} 均值; 计算 $\text{PCC}(\Delta_{\text{pred}} - \mu_{\text{ctx}}, \Delta_{\text{true}} - \mu_{\text{ctx}})$ 。剔除同一菌株/培养基/温度/时间/冻结批次下的共享药物响应分量, 聚焦留出化合物的特异作用机制方向。
药物均值残差（新菌株/上下文的背景调制）	20%	适用 test_strain_only（对应 S2）等新菌株划分。 μ_{drug} = 同药物下训练上下文的 Δ_{true} 均值; 计算 $\text{PCC}(\Delta_{\text{pred}} - \mu_{\text{drug}}, \Delta_{\text{true}} - \mu_{\text{drug}})$ 。剔除同一药物共享的平均作用机制谱, 评估模型能否预测未见菌株/上下文如何调制该响应。
双重未知 / 时间外推	10%	适用 test_both（对应 S3）与 test_time。test_both 以原始 FC + 绝对保真度为主; test_time 以绝对保真度 + 原始 FC 为主。组合外推缺乏稳定的训练实体均值, 不强制以残差为唯一主指标, 重点在完整蛋白质组与扰动方向是否可靠。
高效应蛋白与 DEP 检出	5%	全部划分的补充指标。对 $ \Delta_{\text{true}} > 1$ 的蛋白, 计算方向准确率、高效应 PCC、Recall@K、F1 或 AUPRC。Recall 不单用, 须与 precision、F1 或 AUPRC 组合, 避免「全报阳性」刷高召回。
复现与合规	晋级门槛	全部提交。审查代码、随机种子、归一化流程、外部数据使用与测试泄漏风险, 可作为奖项与晋级门槛。

评分口径要点：

- 基线：组委会提供均值模型、随机森林、梯度提升等基础基线，基因组尺度代谢模型可作参考基线。

- **隐藏机理评估：**隐藏机理评估可用于赛后分析或特别展示（如从预测蛋白质组推断药物作用机制，或对照公开遗传扰动与药物响应数据评估机理一致性），不作主榜排名依据。

提交物：

阶段	提交物	要求
主榜阶段	prediction.csv	按官方模板提交所有样本的响应预测值，不得修改样本 ID
复现审核	代码包或容器、说明文档	说明训练流程、外部资源、随机种子与运行方式；开放知识榜须列出全部外部数据来源

科学意义：

为菌株定向改造与优化提供数据支撑，是「AI 预测 → 湿实验验证」闭环的关键一环。

方向二：小分子-蛋白质结合轨迹预测

科学背景：

小分子与蛋白质的结合本质上是一个动态演化过程，而非静态构象。分子动力学（MD）模拟是刻画结合亲和力、传输性质与口袋动态的关键工具，但对长时间尺度动力学的精确模拟计算代价高昂。以机器学习代理模型（ML surrogate）加速并增强 MD、直接学习并预测结合动力学轨迹，是连接结构生物学与药物设计的前沿方向；相比单一的结合构象预测，轨迹层面的建模更贴近真实的分子行为。

赛题任务：

给定小分子-蛋白质复合物的初始结构与分子动力学轨迹作为训练数据，要求参赛系统学习其动力学规律，构建能够预测未见复合物结合动力学轨迹的模型。任务以单轨迹重建为主榜，可选设多轨迹（同一体系多次独立模拟）子任务以考察对动力学分布的刻画。核心考察点是模型对全新复合物的泛化能力，以及在保证物理合法性前提下对长时程动力学的稳定预测。

数据集：

以 MISATO（Nature Computational Science, 2024）为统一数据基座。

- **数据来源：**MISATO 起始于 PDBbind 的约 2 万个实验解析的蛋白-配体复合物，经半经验量子力学系统性精修，并在水环境下进行分子动力学模拟，是目前规模最大的公开小分子-蛋白质结合动力学数据集之一。
- **规模划分：**13,066 个复合物轨迹用于训练，1,357 个复合物轨迹用于验证与测试；测试集为全新复合物，测试轨迹真值不发布，由组委会保留用于评分。
- **防泄漏：**蛋白-配体体系存在同源冗余，须按蛋白序列一致性与配体骨架/相似度做去泄漏切分，避免训练集中的近同源体系抬高测试成绩。
- **资源与合规：**本方向为统一评测，不分封闭/开放榜。允许使用外部预训练势函数、基础模型或外部 MD 数据，但须完整披露来源；且外部资源不得包含测试集复合物或其近同源体系，以免破坏「未见」泛化的评测（MISATO/PDBbind 为公开数据，此点尤须注意）。

评测集：泛化分层

验证集用于调参与阶段反馈，最终测试集用于排名。以「未见配体」为主评测、核心排名，另设两档泛化挑战（划分依据蛋白序列一致性与配体相似度）：

评价场景	划分方式	考察能力
T1	短程预测（predict next k frames）	局部动力学
T2	长观测预测（train on first 80%, test on last 20%）	较充分观测下的未来预测
T3	少观测预测（train on first 20%, test on last 80%）	有限观测下的长期预测

评分方法：

单个评测集得分按四类指标加权，各指标均相对官方基线归一化为 0–100 分： $\text{Score}_t = 40\% \times \text{Geo}_t + 25\% \times \text{Phys}_t + 25\% \times \text{Dyn}_t + 10\% \times \text{Stab}_t$ 。最终主榜以主评测为核心、两档泛化挑战为辅： $\text{Final} = 50\% \times \text{Score}_{T1} + 30\% \times \text{Score}_{T2} + 20\% \times \text{Score}_{T3}$ 。主榜排名以最终测试集成绩为准，验证集成绩只作阶段反馈。

评分模块	评分对象	评分方式与取向
几何重建 Geo	预测轨迹相对真值的坐标误差（配体重原子 RMSD、口袋原子偏差，按帧并跨时程汇总）	相对基线重建误差归一化；奖励逐帧几何贴近真值、结合位姿不漂移
物理合法性 Phys	键长/键角、原子间碰撞、立体化学与能量合理性	以合法帧比例与违例程度评分（对应基线的 validity）；惩罚穿模、断键、非物理构象
动力学观测量 Dyn	关键接触/氢键距离分布、RMSF 涨落谱、回转半径、沿集体变量的构象/自由能分布与时间相关性	以分布距离（如 JS / Wasserstein）与相关性评分；奖励还原真实涨落与动力学特征，而非只贴近均值构象
长时程稳定性 Stab	短 / 中 / 长时程多时间窗下的误差增长与轨迹稳定性	按 rollout 漂移与长时程稳定性评分；奖励长时程不发散、不塌缩

评分口径要点：

- **基线：**考虑到算力需求，先计算 semi-flexible setting，即蛋白结构在轨迹中不动。

以 NeuralMD（Nature Communications, 2025）为主基线——其以物理约束的多粒度群对称框架（BindingNet + 增广神经微分方程求解器）学习牛顿力学下的结合轨迹，并以「重建误差」与「合法性」为核心评价维度；本赛沿用并扩展该口径，增加动力学分布与长时程稳定性。

- **平凡基线：**另设「静态不动」（预测轨迹恒等于初始结构）、线性外推等平凡基线，用于识别模型是否真正学到动力学，而非退化为静态解。

- **防刷分：**几何指标须与物理合法性、动力学分布联合评价，避免模型通过输出过度平滑或塌缩的轨迹获得虚低 RMSD。

提交物：

阶段	提交物	要求
主榜阶段	预测轨迹文件	按官方模板提交测试集各复合物的预测轨迹（坐标序列），不得修改体系 ID 与帧规范
复现审核	代码包或容器、说明文档	说明训练流程、外部资源、随机种子与运行方式；如使用外部数据或预训练模型，须列出全部来源
决赛应用题	设计报告	在组委会指定的一组靶点-配体上，用所学动力学模型完成一个下游任务（如结合稳定性排序或口袋柔性 / 动力学代理量估计），并与保留的高精度 MD 或实验证据比对

科学意义：

以数据驱动方式加速并增强分子动力学模拟，在保证物理合法性的前提下刻画结合动力学，为基于动态过程的药物设计（亲和力、动力学 / 驻留时间、口袋柔性）提供可迁移的建模范式。

方向三：材料科学文献驱动的科学发现智能体

赛题定位：

本方向面向材料科学领域，核心考察参赛者能否构建一个从文献出发、产出可验证科学发现的智能体系统。要求根据文献调研结果，产出具有可证伪性的科学发现—包括材料_性质关联、隐藏知识连接、新材料设计假设等。

赛题结构：一个基本任务 + 三条可选路线

所有参赛者必须先完成「基本任务」，再从三条进阶路线中任选其一深入；基本任务的产出物将作为后续路线的输入基础。

基本任务：文献调研 Agent（必做）

目标：构建一个能够自主进行材料科学文献调研的智能体（Agent）。

- **文献检索与筛选：**根据队伍给定的研究方向或问题，自主检索并筛选相关文献。
- **知识抽取：**从文献中提取材料成分、结构、性能、模拟方法、合成条件等结构化信息。
- **Research Gap 识别：**识别文献中未被充分探索的方向、矛盾结论或缺失的知识连接。
- **调研报告生成：**输出包含 Research Gap 分析、文献交叉引用的结构化调研报告或文献综述。

推荐工具：Sciverse 科学智能数据库（2500 万+篇论文，支持语义检索与全文定位）、MinerU（开源文档解析引擎，支持 PDF 到结构化内容的深度解析）；鼓励使用 Sciverse API 的 MCP/Skill 接入方式，其调用记录天然构成可审计的证据链。

评估要点：Research Gap 识别的准确率与新颖性、文献溯源的完整性与可信度、调研报告的结构化程度与可读性。

路线 A：构效关系发现（结构-性能关联挖掘）

目标：基于文献调研 Agent 产出的 Research Gap 与知识库，结合开源材料数据库，发掘具有新颖性和可信性的构效关系（Structure-Property Relationship），并提供可信的科学解释。

- **搜索与发现方法：**须使用搜索/优化算法进行探索，推荐方法包括但不限于遗传算法、蒙特卡洛树搜索（MCTS）、贝叶斯优化、符号回归等。
- **关键要求：**搜索方法需与 LLM 深度融合，而非仅用 LLM 生成搜索代码。考察 LLM 如何参与搜索过程——例如生成候选假设作为搜索种群的种子、在搜索中评估中间结果的科学合理性、引导搜索空间的剪枝与聚焦等。
- **可信性与新颖性：**发现的构效关系须有文献证据链支撑，并说明与已有文献结论的关系（区分「新知」与「已知」）；鼓励与 Materials Project、OQMD、NOMAD 等公开数据库交叉验证。

- **领域理解与可解释性：**参赛者需表现出对所选细分领域（如热电、催化、电池材料等）的深刻理解；构效关系须附带清晰的科学解释，而非「黑箱输出」，避免似是而非、无实质价值的低质量文本。
- **加分项：**有材料数据库的验证结果。

路线 B：模拟方法创新

目标：改进材料科学中的计算方法，在保证精度的前提下提升模拟效率。

- **可探索方向：**对 DFT（密度泛函理论）计算的加速与改进；蒙特卡洛模拟的效率提升；分子动力学（MD）模拟的新架构；引入生成式模型（如扩散模型、流模型等）替代或增强传统模拟方法。
- **参考基础：**已有机器学习势函数（如 MACE、NequIP、CHGNet 等），变分蒙卡、张量网络、NAS 等前沿方向。
- **评估要点：**在公认 benchmark（如 MD17、QM9、Materials Project 轨迹等）上的表现，或在细分领域的优异之处（如某种特定材料的相变模拟精度提升）；模拟效率与精度保持之间的权衡；方法的可复现性。
- **加分项：**有实验验证结果，或在真实材料体系上展示实用价值。

路线 C：合成路线与工艺设计

目标：基于文献调研发现的 Research Gap，构建能够生成合成路线或优化合成工艺的智能体系统。

- **合成路线生成：**给定目标材料，自动生成可行的合成路线（前驱体选择、反应条件、步骤顺序等），并给出文献依据。
- **工艺优化：**针对现有合成工艺，提出改进方案（产率提升、条件简化、成本降低等）。
- **合成验证：**通过文献追溯、计算模拟或实验验证，实现生成路线的可验证性。

- **核心要求：**系统须能展示其推理过程（为什么选择这条路线/这个条件）；合成建议须有文献或化学原理支撑，不能凭空生成；鼓励将逆向合成分析（Retrosynthesis）与 LLM 推理能力结合。
- **加分项：**有实验验证结果，或对现行工艺实现了可量化的优化。

其他路线：选择实验自动化闭环装置、世界模型赋能材料等新颖路线亦可。

材料方向数据与工具资源：

资源	内容	获取方式
Sci-Base	2500 万+篇论文、6000 亿+ tokens，覆盖含材料科学在内的 10 个学科	Hugging Face： opendatalab/Sci-Base
Sciverse API	4.66 亿条学术元数据、2800 万+全文证据片段，语义检索	sciverse.opendatalab.com 注册
MinerU	开源文档解析引擎（PDF→结构化内容）	mineru.net
Materials Project	材料结构与性能数据库	materialsproject.org
OQMD / NOMAD	开放量子材料数据库 / 计算材料科学数据仓库	oqmd.org / nomad-lab.eu

材料方向评估体系：

材料方向内部采用「基本任务 50% + 进阶路线 50%」的细分评估口径，作为本方向在算法赛题通用评审维度下的实施细则。

- **基本任务（50%）：**Research Gap 识别质量（准确性、新颖性、可操作性）、文献溯源完整性（每条 Gap 有清晰文献证据链）、报告质量（结构化程度与可读性）。

- **进阶路线（50%）**：路线 A 综合评分，重点考察搜索方法与 LLM 的融合深度，以及物理机制解释的说服力、对已有理论的推广甚至颠覆程度；路线 B 看公认 benchmark 表现或细分领域改进幅度，考察创新性与实用性；路线 C 看合成路线可行性、优化方案有效性、验证手段充分性。

材料方向提交物：

阶段	提交物
基本任务	文献调研报告（含 Research Gap 清单 + 文献交叉引用 + 证据链）+ 系统说明
进阶路线	路线 A：构效关系清单 + 证据链 + 解释文档；路线 B：代码 + benchmark 结果 + 方法说明；路线 C：合成/优化方案 + 验证证据
最终	完整技术报告 + 可复现代码/容器

设计理念：基本任务保证门槛（所有参赛者至少有文献调研 Agent 的产出，避免无从下手）；三条路线覆盖知识发现、计算方法创新与工程应用三类能力，不同背景的参赛者都能找到发力点；每条路线都配有明确评估标准与可用数据源，避免空中楼阁；加分项鼓励实验闭环，推动「预测→验证」的科研闭环。

03 提交要求（算法赛题）

按初赛、复赛、决赛三阶段提交，各阶段均为必交。数据/指标明确的方向另有方向内提交物（如虚拟细胞的 prediction.csv 与复现审核材料），并入相应阶段。

阶段	提交材料与内容说明	是否必交
初赛	方案说明文档、技术路线概述：说明所选方向、科学问题理解、技术方案与预期方法路线；可附初步实验或可行性验证。	是
复赛	可运行代码仓库、实验结果报告、科学意义阐释、依赖披露：提交完整代码（含 README、环境配置、运行说明）、完整实验结果，以及方法的科学意义说明与依赖/授权披露。	是

阶段	提交材料与内容说明	是否必交
决赛	海报/路演材料、现场展示、最终代码仓库、项目一页纸：聚焦方法、核心结果与科学意义，现场展示与专家问答。	是

04 统一评审标准

算法赛题以统一标准评分、统一排名，全赛道决出一名冠军。方向内的量化成绩先归一化为可比分数，再进入下列跨方向评审维度：

评审维度	建议权重	说明
技术性能	45%	方向内量化成绩经归一化后的表现——虚拟细胞取最终主榜的六模块加权总分，小分子取三场景 T1/T2/T3 加权的最终主榜得分（相对 NeuralMD 基线归一化），材料取「基本任务 + 进阶路线」综合分。各方向均以相对基线 / 相对参照的归一化分进入，以保证跨方向可比。
科学意义	30%	结果对该科学领域是否有真实意义，是否超出已有工作的边界。
方法创新性	20%	方法是否有新颖的技术设计，而非对已有方法的简单集成。
开源贡献	5%	代码、模型或数据处理管线的开源质量与可复用性——完整的文档、清晰的许可，以及可被社区接续使用与复现的程度。

各方向的方向内评分口径见第二节；统一评审在方向内成绩基础上叠加科学意义与创新性，由评审组做跨方向校准，产生唯一的算法赛题总排名与冠军。

待确认（评审设计）：（1）虚拟细胞设「封闭数据榜 / 开放知识榜」两个方向内榜，需明确二者如何进入统一总排名——建议以封闭数据榜作为主排名输入，开放知识榜作为并行的方向内荣誉或专项奖；（2）跨方向可比性依赖各方向都产出「相对基线 / 相对参照」的归一化分，材料方向的综合评分需给出与之对齐的归一化口径。以上两点建议在评委手册中固定。

05 开源与合规要求

- **开源代码：**初赛不强制提交代码，但需说明开源计划与边界；进入复赛/决赛后需提交可运行代码或等价可验证材料，并提供可访问仓库。
- **部署/复现：**复赛起需提供运行入口、依赖安装、配置方法、随机种子与复现说明。
- **商业 API / 闭源模型：**允许使用商业 API 与闭源模型，但必须披露调用环节、费用假设、权限范围、可替代性与迁移成本，及其对可复现性的影响。
- **已有项目：**允许基于已有项目继续开发，但需说明原项目来源、团队贡献范围、新增创新点与原协议兼容性。
- **数据与依赖：**使用公开数据集需遵守对应授权协议；官方数据集使用规范以赛题文档为准。未发表的官方数据仅限本次竞赛使用，需签署数据使用协议，不得再分发或另作他用。需完整披露开源依赖、商业服务、外部数据来源、许可证与关键版本信息。

注：本资料为当前规划版本，赛程、数据集、评测细则、资源与提交方式可能根据赛事安排调整，最终以 GOAI 世界人工智能开源大赛组委会正式发布为准。

开放探索赛题

题目类型二 · 详细说明

详细说明文档 · 2026 年 7 月 · 规划版本

01 赛题类型定位

部分重要的科学问题尚未被结构化为标准的评测任务。开放探索赛题面向这类问题，鼓励参赛者自己提出并定义一个值得探索的科学问题，把它转化为一个 Agent 可以进入、尝试、修正并持续探索的环境。

参赛团队在自己所在的科学或研究领域中，找到一个尚无公认答案的问题，定义相应的探索环境与发现信号，构建可运行的探索系统，并说明探索过程带来的科学或研究价值。与算法赛题不同，本类题目不预设标准答案，负结果被明确允许——关键在于能否清晰解释探索过程说明了什么。

02 参赛要求：三条核心约束

提交的项目须同时满足以下三条核心约束，这也是问题定义文档需要讲清楚的三件事。

约束一：真实问题

所聚焦的问题必须真实存在，目前没有公认答案或尚未被充分结构化。需用文献、数据、专家经验或现实系统来说明这一点，而非人为构造的玩具问题。

- 判断依据：**能用文献综述、公开数据的缺口、领域专家的共识性困惑，或某个现实系统中反复出现的难题来佐证「这个问题真的悬而未决」。

约束二：探索环境

需说明 Agent 在什么环境里行动、看到什么、能改变什么、如何获得反馈。环境是本类赛题的核心载体。

- **环境形态举例：**实验模拟器、文献空间、市场微观结构模拟、分子生成反馈循环、城市干预仿真等，均可作为探索环境。
- **须说明：**哪些部分是固定的、哪些部分可被 Agent 探索、反馈信号如何产生与记录，都需在环境设计中交代清楚。

约束三：发现信号

需提前说明「什么算发现」——发现信号应在探索开始前就被定义，而非事后追认。

- **信号类型：**正向发现、异常、反例、稳定的负结果、失败模式，也可以是对原问题定义本身的修正。
- **评审取向：**一个被清晰解释的负结果，与一个正向发现同样有价值；关键是能说明它对原问题意味着什么。

03 适用领域

不限学科。自然科学、工程科学，以及城市系统、金融市场、社会科学、公共政策等复杂系统方向均可参与。但项目须指向真实的研究问题，而非单纯的业务优化或应用集成。

04 参赛支持材料

为帮助参赛者理解开放命题，组委会将提供以下辅助材料，相关内容将逐步发布：

- **样例库：**正面 / 负面样例，帮助参赛者理解什么样的问题定义与探索设计是合格的、什么是不合格的。
- **轻量环境骨架参考：**帮助参赛者说明哪些部分固定、哪些部分可探索、如何记录运行日志。

- **创新矩阵说明：**帮助参赛者定位自己项目的探索类型与创新点。

05 参赛样例与自检

以下样例并非正式赛题，也不限定方向，作用是帮助参赛者校准「开放但可评审」与「看起来热闹但价值不足」之间的差别。每个样例给出同一方向下的不合格版本与合格版本，供对照参考；完整样例库（含更多领域）将作为辅助资料逐步发布。

样例 A: Physical AI / 多物理场仿真

不合格版本 用 AI 自动设计最优工程结构

「最优工程结构」范围过大，未限定场景、载荷、材料与制造约束，仅生成 CAD 形状，也未说明热、流、固、电磁等物理场如何耦合，缺少最小参照系与数值收敛 / 物理合法性检查——像生成式设计 demo，而非可评审的研究环境。

合格版本 热-流-固耦合条件下微通道冷却结构的探索环境

- **研究问题：**在固定泵功和制造约束下，是否存在兼顾散热效率、压降与结构可靠性的非直觉微通道拓扑？
- **固定部分：**材料参数、入口温度 / 流量范围、制造最小特征尺寸、CFD / FEA 求解设置与收敛判据。
- **可探索部分：**通道拓扑、分叉方式、局部截面、扰流结构、冷却路径。
- **反馈机制：**最大温度、温度均匀性、压降、热应力、数值收敛状态、制造可行性。
- **发现信号：**Agent 找到一类在多个工况下稳定优于直通道 / 人类启发式结构的拓扑规律，或发现某类看似合理的结构在耦合场中系统性失效。

评判要点：是否真正处理多物理场耦合而非单指标优化；数值求解是否稳定、网格 / 时间步 / 收敛条件是否说明清楚；是否有直通道、蛇形通道、随机扰动等平凡解参照；是否报告失败结构及其物理原因，避免把求解器噪声当成发现。

样例 B：火箭发动机 / 燃烧稳定性设计

不合格版本 用 AI 设计更强的火箭发动机

目标过大，混合比、推力等级、冷却方式、燃烧室尺度均不清楚，且仅优化推力或比冲、忽略燃烧不稳定与结构约束——太宏大，且容易滑向危险的性能优化叙事。

合格版本 液体火箭发动机喷注器几何对燃烧不稳定窗口的探索环境

- **研究问题：**在给定推进剂组合与燃烧室尺度下，喷注器几何如何影响低频 / 高频燃烧不稳定的出现窗口？
- **固定部分：**推进剂物性范围、燃烧室几何、简化反应模型、声学边界条件、稳定性判据与安全约束。
- **可探索部分：**喷注孔排布、孔径分布、撞击角、旋流强度、局部混合结构。
- **反馈机制：**压力振荡幅值、热释放耦合指标、混合均匀性、壁面热流、数值收敛状态。
- **发现信号：**发现一类能扩大稳定燃烧窗口的喷注结构原则，或发现某类常见喷注直觉在特定声学模式下失效。

评判要点：是否把问题限定在「稳定性窗口探索」而非泛泛追求更大推力；是否说明仿真模型的适用范围与简化假设；是否有平凡 / 随机 / 经典喷注器参照；是否报告不稳定案例。特别地，公开材料应停留在抽象设计原则层面，避免输出可直接用于危险用途的完整工程参数包。

样例 C：核聚变 / 等离子体运行窗口

不合格版本 用 AI 实现可控核聚变

目标等于终极问题，比赛周期内不可评审；未限定托卡马克 / 仿星器、放电阶段、控制变量或诊断信号，只追求约束时间或输出功率——方向重要，但问题没有切开。

合格版本 托卡马克边界等离子体运行窗口的 Agent 探索环境

- **研究问题：**在给定装置与诊断数据范围内，能否识别一类兼顾高约束、低边界不稳定风险与可控热负荷的运行窗口？

- **固定部分：**历史放电数据、简化输运 / 边界模型、诊断信号、机器保护约束、可访问控制变量范围。
- **可探索部分：**加热功率时序、密度爬升策略、杂质注入策略、磁构型参数、控制动作顺序。
- **反馈机制：**约束质量、边界不稳定指标、偏滤器热负荷、破裂风险代理指标、控制平滑性。
- **发现信号：**Agent 找到一类跨多个放电片段复现的运行路径，或发现某种控制直觉在特定边界条件下会系统性提高风险。

评判要点：是否限定在可探索的运行窗口而非「解决聚变」；是否尊重机器保护、可控变量范围与诊断噪声；是否有无干预 / 历史相似放电参照；是否区分真实物理信号与模型代理指标偏差；是否记录高风险 / 失败路径及原因。

样例 D：量子光学 / 光子实验设计

不合格版本 用 AI 自动发现新的量子实验

「新的量子实验」过大，未限定平台、元件集合与目标态，仅生成光路图，缺少物理可实现性、损耗、探测效率与误差模型，也未说明什么算新颖、什么算可验证——像创意生成而非实验探索环境。

合格版本 面向高维纠缠态制备的量子光学实验探索环境

- **研究问题：**在给定光学元件集合与损耗模型下，是否存在更简单或更鲁棒的高维纠缠态制备方案？
- **固定部分：**可用元件库、光源假设、损耗 / 探测效率模型、实验可搭建约束、目标态保真度计算方式。
- **可探索部分：**光路拓扑、元件顺序、相位设置、后选择规则、测量基选择。
- **反馈机制：**目标态保真度、成功概率、元件数量、损耗敏感性、与已知方案的结构差异。

- **发现信号：**出现一类更少元件、更高鲁棒性或更易实验验证的光路结构，或发现某类看似简洁的方案对损耗极端敏感。

评判要点：是否有明确元件库与实验约束；是否检查保真度、成功概率与损耗鲁棒性而非只看理想态；是否有已知 / 随机 / 简化光路参照；是否说清新颖性（新拓扑、新参数区间还是新鲁棒性发现）；结果能否被实验物理学家检查。

样例 E：金融市场微观结构

不合格版本 用 Agent 自动寻找高收益量化策略

只追求回测收益率，容易过拟合与数据泄露，没有研究问题、只有交易目标，机制解释薄弱——不宜作为开放赛道主推方向。

合格版本 订单簿冲击恢复过程中的异常流动性机制探索

- **研究问题：**在特定市场与时间尺度下，大额订单冲击后，流动性恢复是否存在可解释的阶段性机制？
- **固定部分：**历史订单簿数据切分、交易成本假设、时间窗口、不可泄露未来信息规则。
- **可探索部分：**事件窗口、特征组合、机制假说与检验方式。
- **反馈机制：**跨时期稳健性、机制解释力、风险约束、与简单统计参照的差异。
- **发现信号：**发现一种在多个时期复现、可解释且不依赖未来信息的流动性恢复模式。

评判要点：是否严格时间切分以避免未来信息泄露；是否披露交易成本、滑点与风险约束；是否把收益率降为辅助指标而非核心发现；能否提出机制解释并跨时期、跨市场状态复现。

样例 F：AI 社会科学 / 人文计算

不合格版本 用大模型研究社会和人类文明

目标过大、概念不可操作，仅让 LLM 扮演不同人群做访谈或投票，缺少真实语料、行为数据、机制假设或可验证标准，容易把模型偏见当成社会规律——有趣但不可评审，且风险较高。

合格版本 跨学科同行评审文本中「问题定义质量」的演化机制探索

- **研究问题：**在不同学科的评审文本中，哪些语言与论证结构会推动一个模糊研究问题变得更可检验、更可执行？
- **固定部分：**匿名化评审语料、学科标签、时间切片、人工标注子集、伦理与隐私约束。
- **可探索部分：**Agent 提出的问题定义特征、证据链结构、反驳模式与修改建议，并在不同语料切片中检验。
- **反馈机制：**人工标注一致性、跨学科稳定性、预测后续修改质量的能力、反例检索结果。
- **发现信号：**发现一类可跨学科复现的问题定义改进模式，或发现某类评审话语在不同学科中含义完全不同。

评判要点：是否使用真实语料或清楚的人工标注协议而非纯 LLM 角色扮演；是否处理隐私、偏见与语料代表性；能否区分「文本相关性」与「机制解释」；是否有空模型 / 随机标签 / 简单文本特征参照；是否主动寻找反例。

更多样例（如面向气动-结构约束的柔性翼型反向设计、面向探索 Agent 的动态评测范式等）将收录于完整样例库。后者属于「元环境 / 评测范式」类，需以具体领域实例跑通后，才作为特殊贡献或范式创造类候选考虑。

强项目与弱项目的特征

一个强开放赛道项目通常同时满足：

- **问题真实：**领域内确实存在未解或尚未被充分结构化的问题。
- **切片适中：**不是终极问题，而是比赛周期内能探索的局部。
- **环境清楚：**哪些规则固定、哪些变量可探索、反馈从哪里来，都交代清楚。
- **发现提前定义：**正结果、负结果、异常或反例都能被提前定义并解释。
- **参照系合理：**能说明随机探索、空模型、平凡解或无干预情形会产生什么。
- **可检查且可延续：**评委能看到 Agent 如何行动、失败、保留或丢弃结果；即使失败也让问题定义变清楚；产物别人能接着跑、接着改、接着验证。

弱项目往往只有：一个宏大标题、一个 LLM 工作流、一张漂亮结果截图、一个无法复查的故事、一个事后定义的成功标准，或一个纯工程优化指标。

参赛者自检清单

提交前，建议用以下问题自查：

- 如果去掉 AI，这个问题本身还成立吗？
- 如果去掉领域名，这还是研究问题，还是只剩工程任务？
- Agent 的行动是否真的会改变后续观察和决策？
- 反馈是否足以让 Agent 迭代，而不是只给最终分数？
- 发现信号是否能被领域专家理解？
- 最小参照系是否能排除「只是随机运气」？
- 结果是否可能来自数据泄露、仿真漏洞、数值不稳定或 LLM 幻觉？
- 失败结果是否能帮助改进下一版问题定义？

06 提交要求（开放探索赛题）

按初赛、复赛、决赛三阶段提交，各阶段均为必交。

阶段	提交材料与内容说明	是否必交
初赛	问题定义文档（≤ 4 页）：说明看见了什么问题、为什么 AI 可以介入、如何定义探索环境、什么算发现信号、最小参照系是什么。	是
复赛	最小可运行探索环境、探索日志、参照系设计：提交可运行环境、至少一次完整运行日志、随机探索或平凡解等参照系，以及 README 与复现说明。	是
决赛	探索报告、答辩材料、最终代码仓库：说明探索过程中的正结果、负结果、异常或问题修正究竟意味着什么；负结果被明确允许。	是

07 评审标准（开放探索赛题）

本类题目与算法赛题独立评审、独立排名，采用以下三个维度。

评审维度	建议权重	说明
问题定义与环境设计质量	45%	问题是否真实且切片得当；环境是否抓住问题本质；固定部分、可探索部分和反馈机制是否清楚。
探索过程与科学/研究信号	35%	是否有意义信号：正向发现、异常、反例、被清晰解释的负结果，或问题定义的有效修正。
可检查性与可延续性	20%	是否有最小参照系、运行日志、复现说明和后续研究路径；能否沉淀为社区可接续的问题包或环境包。

08 开源与合规要求

- **开源代码：**初赛不强制提交代码，但需说明开源计划与边界；进入复赛/决赛后需提交可运行环境或等价可验证材料，并提供可访问仓库。
- **部署/复现：**复赛起需提供运行入口、依赖安装、配置方法、随机种子与复现说明。
- **商业 API / 闭源模型：**允许使用商业 API 与闭源模型，但必须披露调用环节、费用假设、权限范围、可替代方案与迁移成本，及其对可复现性的影响。
- **数据与依赖：**开放探索赛题使用的数据需说明来源与授权状态；需完整披露开源依赖、商业服务、外部数据来源、许可证与关键版本信息。

注：本资料为当前规划版本，赛程、数据集、评测细则、资源与提交方式可能根据赛事安排调整，最终以 GOAI 世界人工智能开源大赛组委会正式发布为准。